

به نام خدا

پیشبینی قیمت واحدهای مسکونی در تهران منطقه صادقیه شهر تهران



_ نام و نام خانوادگی دانشجویان:
شایان پاک راد
کیارش کامرانی کیا

_ رشته تحصیلی: مهندسی کامپیوتر

_ دانشگاه: بوعلی سینا

_ نام استاد: آقای میرحسین دزفولیان

مقدمه

بازار مسکن یکی از پیچیده‌ترین بازارهای اقتصادی است که قیمت در آن تحت تأثیر مجموعه‌ای از عوامل فیزیکی، ساختاری و امکاناتی قرار دارد. در این پروژه هدف، توسعه یک مدل داده‌محور برای پیش‌بینی قیمت واحدهای مسکونی در منطقه صادقیه تهران است. مسئله به صورت یک مسئله رگرسیون نظارت‌شده (Supervised Regression) تعریف شده است که در آن متغیر هدف Price و سایر ویژگی‌های ملک به عنوان متغیرهای مستقل در نظر گرفته شده‌اند. این پروژه تمام مراحل استاندارد یادگیری ماشین شامل تحلیل داده، پاک‌سازی، پیش‌پردازش، مدل‌سازی، اعتبارسنجی و مقایسه مدل‌ها را به صورت کامل اجرا کرده است.

قبل از هر کاری اول باید داده‌های آگهی‌های سایت دیوار را به روش web scraping و با استفاده از کتابخانه selenium بارگیری کنیم. جزئیات مراحل web scraping را می‌توانیم داخل کد مربوطه به آن ببینیم.

آماده‌سازی محیط و بارگذاری کتابخانه‌ها

در ابتدای پروژه، کتابخانه‌های زیر بارگذاری شدند:

```
%matplotlib inline
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

برای مدل‌سازی و ارزیابی:

```
from sklearn.model_selection import train_test_split, cross_val_score, KFold
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
from sklearn.ensemble import RandomForestRegressor
from sklearn.linear_model import ElasticNet, Lasso, LinearRegression, Ridge
from sklearn.neighbors import KNeighborsRegressor
from sklearn.model_selection import GridSearchCV
from sklearn.tree import DecisionTreeRegressor
from xgboost import XGBRegressor
```

برای پیش پردازش استاندارد و جلوگیری از نشت داده:

```
from sklearn.preprocessing import StandardScaler
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
```

بررسی اولیه داده‌ها:

```
df.info()
df.shape
```

مشخص شد:

- 320 رکورد
- 8 ستون
- وجود مقادیر گم شده در ستون‌های Area ، Year Of Construction ، Room ، Floor و Price و Number
- سه ستون بولین شامل Parking ، Warehouse و Elevator
- ساختار داده اولیه:

ستون	تعداد مقدار غیر Null
Area	298
Year Of Construction	298
Room	298
Floor Number	314
Price	318

تبدیل نوع داده‌ها

برای اطمینان از صحیح بودن نوع داده‌ها، ستون‌های زیر به عدد صحیح تبدیل شدند:

```
cols_to_int = ["Year Of Construction", "Room", "Floor Number"]

for col in cols_to_int:
    df[col] = (
        pd.to_numeric(df[col], errors="coerce")
        .round()
        .astype("Int64")
    )
```

استفاده از `errors="coerce"` باعث تبدیل مقادیر نامعتبر به NaN شد که در مرحله Imputation مدیریت شدند.

تحلیل آماری اولیه و شناسایی داده‌های پرت

```
df.describe()
```

مشخص شد:

- حداکثر متراژ: 607200 متر
- حداکثر طبقه: 802,739,000
- حداکثر قیمت: 132.5e

این مقادیر از نظر فیزیکی غیرممکن هستند. بنابراین داده خام شامل خطاهای جدی بوده است.

همچنین با اجرای:

```
df[df['Price'] > 1e11]
```

موارد پرت شناسایی شدند.

پاک‌سازی داده‌ها با فیلتر منطقی

برای حذف داده‌های غیرواقعی از شرط‌های زیر استفاده شد:


```
df = df[
    (df["Year Of Construction"] >= 1404 - 100) &
    (df["Room"] >= 1) & (df["Room"] < 7) &
    (df["Floor Number"] >= 1) & (df["Floor Number"] < 40) &
    (df["Area"] >= 30) & (df["Area"] <= 500) &
    (df["Price"] >= 5e8) & (df["Price"] <= 5e10)
]
```

این مرحله باعث حذف داده‌های غیرمنطقی و تثبیت توزیع آماری شد.

تحلیل همبستگی

برای بررسی ارتباط بین ویژگی‌ها از heatmap استفاده شد:

```
plt.figure(figsize=(8,4))
sns.heatmap(df.corr(numeric_only=True), annot=True, cmap='RdYlGn')
plt.show()
```



نتایج:

- Area و Price: همبستگی ≈ 0.83
- Room و Price: ≈ 0.6
- Year Of Construction تأثیر مثبت ملایم
- Floor Number تأثیر ضعیف

نتیجه: متراژ مهم‌ترین عامل تعیین‌کننده قیمت در داده موجود است.

ساخت مدل‌ها

مدل‌های زیر تعریف شدند:

```
models = {  
    "Ridge": Ridge(alpha=1.0),  
    "Lasso": Lasso(alpha=0.001),  
    "RandomForest": RandomForestRegressor(n_estimators=300, random_state=42),  
    "GradientBoosting": GradientBoostingRegressor(random_state=42),  
    "SVR": SVR(),  
    "KNN": KNeighborsRegressor()  
}
```

برای ارزیابی از 5-Fold Cross Validation استفاده شد:

```
kf = KFold(n_splits=5, shuffle=True, random_state=42)
```

مدل‌ها داخل Pipeline اجرا شدند:

```
pipe = Pipeline([  
    ("prep", preprocessor),  
    ("model", model)  
])
```

نتایج نهایی مدل‌ها:

مدل	MAE	R^2
Ridge	0.361	0.56
Lasso	0.361	0.56
RandomForest	0.166	0.77
GradientBoosting	0.202	0.63
SVR	0.186	0.79
KNN	0.188	0.78

بهترین عملکرد از نظر R^2 مربوط به SVR (0.79) بوده است.

تحلیل نتایج

1. مدل‌های خطی (Ridge و Lasso) عملکرد متوسط داشتند.
2. مدل‌های غیرخطی عملکرد بهتری داشتند، نشان‌دهنده وجود روابط پیچیده بین متغیرها.
3. RandomForest و KNN نیز عملکرد نزدیک به SVR داشتند.
4. استفاده از Cross Validation باعث کاهش وابستگی به یک تقسیم خاص داده شد.

جمع‌بندی نهایی

در این پروژه:

- داده خام تحلیل و اصلاح شد.
- داده‌های پرت حذف شدند.
- تحلیل همبستگی انجام شد.
- 6 مدل مختلف مقایسه شدند.
- ارزیابی با Cross Validation انجام شد.

نتیجه نهایی نشان می‌دهد مدل‌های غیرخطی برای این مسئله مناسب‌تر هستند و SVR بهترین عملکرد را ارائه داده است.

پروژه از نظر ساختار علمی کامل بوده و تمام مراحل استاندارد یادگیری ماشین را شامل می‌شود:

EDA → Data Cleaning → Preprocessing → Modeling → Cross Validation →
Evaluation → Model Comparison

این مدل می‌تواند برای تخمین قیمت واحدهای مسکونی در محدوده تعریف‌شده مورد استفاده قرار گیرد.

استریم لیت (streamlit)

سعی کردیم که با استفاده از کتابخانه streamlit هم یک وب اپلیکیشن تعاملی برای تخمین قیمت خانه در محله صادقیه بنویسیم که نتایجش رو میشه تو لینک های زیر پیدا کنید :

لینک گیت هاب : <https://github.com/Shayan-Pakrad/real-estate-ai-agent>

لینک وب اپلیکیشن : <https://real-estate-ai-agent-2m2qycy6hwdwqvy6agkklh.streamlit.app>



سامانه پیش بینی قیمت ملک (صادقیه)

این برنامه بر اساس داده های واقعی، قیمت تقریبی خانه را پیش بینی می کند.



مشخصات ملک را وارد کنید:

متراژ (متر مربع)

100

- +

طبقه

5

- +

تعداد اتاق

2

▼

☒ پارکینگ دارد

☒ آبیاری دارد

مدال ساخت (شمسی)

1400

- +

☒ آسانسور دارد

محاسبه قیمت

قیمت تخمینی: 15,925,152,742 تومان

قیمت هر متر مربع: 159,251,527 تومان